



博士課程進学に関する統計的因果探索の 非線形効果の可視化

高山 正行^{A, B}, 小松 尚登^B, ファム テトン^{B, C}, 前田 高志 ニコラス^{A, B, C, D, E},
三内 顕義^{A, B, F, G, H}, 小柴 等^{A, B}, 清水 昌平^{A, B, C, F, I}

A: 科学技術・学術政策研究所 (NISTEP)
B: 滋賀大学
C: 理化学研究所 革新知能統合研究 (AIP) センター
D: 東京電機大学
E: 学習院大学
F: 京都大学
G: 東京大学
H: 国立情報学研究所
I: 大阪大学



Japan Science and Technology Agency


CREST
Core Research for Evolutional Science and Technology




信頼される AI システム
Trusted quality AI systems

Mail: masayuki-takayama@biwako.shiga-u.ac.jp

NISTEP「修士課程（6年制学科を含む）
在籍者を起点とした追跡調査」（2021）



NISTEP「博士(後期)課程 1年次における進路意識と経済的支援状況に関する
調査 - 令和 4 年度（2022年12月～2023年1月）実施調査 -」（2023）



- 研究力強化の文脈の中でも重要視される、(イノベーションの担い手としての) **博士課程進学者数の増加**
- **経済的支援・研究環境改善・アカデミア&産業界のポスト拡充、雇用条件改善等の重要性**は、常々議論されている
- 最近では、文部科学省による経済的支援施策等も充実してきた
(☞ その観点での因果推論の研究が、2B05でも発表される予定)

- 今後、**継続的に予見性をもって、研究力強化のための博士人材を安定供給**できるようにするかが重要
- しかし、**他の資源配分との兼ね合いも考慮した「ワイズスペンディング」**に向けては、**経済的支援等の政策効果がどの程度のものか**、一定程度、因果メカニズムの説明性を担保の上、予測シミュレーションを実現していくことも重要

⇒ 定量的な議論が可能な変数に基づいて、マクロスコピックな統計データから、**博士課程進学者数に関する各種要因の因果関係の全体像を、把握したい**


【先行研究】

- 国立大学別のデータセットを構築し、データ駆動で統計的に因果関係を見つけ出す統計的因果探索アルゴリズムのうち、

- ・I/Oの定量分析や予測の議論にもつなげやすい **LiNGAM** (**L**inear **N**on-**G**aussian **A**cyclic **M**odel)
- ・条件付き独立性に基づくアプローチで、未観測共通要因の存在可能性も検出する **FCI** (**F**ast **C**ausal **I**nfERENCE)

等で分析することで、大学群別の特徴を捉えながら、博士課程進学等のメカニズムに関する示唆

国立大学の類型Ⅲ（≒16の研究大学）のデータで FCIとbootstrapを組み合わせて辺が出る確率を計算した結果



高山ほか，研究・イノベーション学会 第39回年次大会，1D06(2024)

【残っている課題】

- ✓ 挙動の大雑把な把握には、線形モデルでも一定対応可能だが、予測シミュレーションに繋げるためには、非線形性への対応も検討しておく必要
- ✓ モデルが複雑になる分、実務を担う者が理解・採用しやすくなるような工夫が必要 (ex. 因果効果の可視化)

最近、技術的なアップデートがなされ、実装の見通しが立ったところ

博士課程進学に関する政策研究において、
非線形性も考慮され、より説明性の高い因果モデルの構築と、
それに基づく信頼性の高い予測シミュレーションを可能とするため…

✓ 非線形な関数形にも対応した因果探索アルゴリズム

RESIT (**RE**gression with **S**ubsequent **I**ndependence **T**est) の適用

✓ 非線形な総合因果効果の可視化シミュレーション

を実施。

データセットの基本構造

✓（国立86大学）×（2012-2022年度の11か年度）で、以下の10変数構成のデータセットを構築（最大946点）

変数名	内容	出典	変数構成の考え方
M_graduate	修士課程等修了者数	NIADが公開する大学基本情報を基に加工	博士課程進学者数に関する変数
D_entrance	博士課程進学者数		
Ph.D_graduate	博士課程修了者数		博士課程修了者の修了直後のキャリアに関する変数
PosDoc	博士課程修了直後のポスドク就職者数		
AcaPos	博士課程修了直後の大学教員就職者数		
Basic_income	運営費交付金収益額	各国立大学法人の財務諸表等から引用	大学の研究環境に係る変数
Students_per_teacher	教員一人当たり学生数	NIADの国立大学の財務指標	
DC1	DC1採択者数	JSPSから過去に公開されたDC1採択者一覧のデータを基に加工	博士課程進学者の経済的支援に係る変数
KAKEN	科研費配分額	JSPSから過去に公開された機関別の配分額を収集	修士課程修了者数・博士課程修了者数の間に存在しうる共通要因として考えられる候補
Papers	論文等の発表数	OpenAlexで当該機関所属の著者が一人でもいる文献をカウント	

因果探索の使用・分析条件

- 文部科学省で以前採用されていた**運営費交付金の重点支援の3類型**でグループ化し、グループごとに分析
- 時系列は、いったん1年先の遅延効果までを考慮（1年後の変数は、例えばPosDoc_L1というように、“_L1”を付記）
- 探索に当たって、**因果的順序の制約条件となる事前知識**も、時系列等に沿って導入（詳細は予稿参照。最近技術的に整備されたのはここ！）

【重点支援3類型の分類】

重点支援類型	定義・特徴	大学数 (データ点数)
類型Ⅰ	大雑把には下記以外	55 (605)
類型Ⅱ	専門分野の特性に応じた強み・特色のある分野で教育研究を推進	15 (165)
類型Ⅲ	全学的に卓越した教育研究、社会実装を推進	16 (176)

分析に応じた因果探索アルゴリズムの採用

非線形に対応した統計的因果探索アルゴリズム RESITを軸として、
分析に応じて適用方法を変える。

分析A: 線形性を仮定した因果探索と非線形に拡張した因果探索の比較

✓ DirectLiNGAMとRESITを実施し、因果グラフを比較

分析B: 介入を想定した非線形総合因果効果の可視化と統計的信頼性評価

✓ 1,000回のbootstrap samplingを行い、それぞれでRESITを実行して得られたモデルに基づき、
総合因果効果を計算し、統計的信頼性も評価

アルゴリズムの種類	探索の考え方	仮定① 巡回性	仮定② 未観測共通要因	仮定③ 関数系の仮定	アウトプット
DirectLiNGAM S. Shimizu, <i>et al.</i> , JMLR, 2011.	線形構造方程式の誤差変数の依存性を最小化する因果的順序を決定→線形回帰	非巡回	×	線形構造方程式 (誤差関数も非ガウス)	因果グラフ + 構造方程式の因果係数の推定値
RESIT J. Peters, <i>et al.</i> , JMLR, 2014.	非線形構造方程式の誤差変数の依存性を最小化する因果的順序の決定→非線形回帰		×	非線形構造方程式 (誤差関数の分布は任意)	因果グラフ

変数集合 $\{x_i\}$ についての構造的因果モデルとして、


以下の**Additive Noise Model**を仮定

$$x_i = f_i(PA(x_i)) + e_i$$

$PA(x_i)$: 変数 x_i の親の集合

仮定:

- (1) 関数 f_i が一定の微分可能性要件を満たす
- (2) 非巡回性(Acyclic)
- (3) 外生変数 e_i 同士が互いに独立(未観測共通要因なし)



アルゴリズム※¹の流れ

- ① 非線形性を加味した回帰器※²で、 x_i を x_j で回帰し、残差を計算
- ② 残差同士の依存性について、非線形・非単調でも検出できるよう、Hilbert-Schmidt Independence Criterionを用いて計算
- ③ ①②について、逆 (x_j を x_i で回帰) を行い、依存性がより小さくなるような因果的順序を決定
- ④ ①～③をすべてのペアで行い、全変数について、因果的順序を決める
- ⑤ ④で定めた因果的順序に沿って、改めて非線形性を加味した回帰器により、Additive Noise Modelを仮定してfit。ただし、冗長な有向辺については枝刈りで削除

※¹ 本研究では、pythonパッケージ "lingam"(<https://github.com/cdt15/lingam>)で実装されたアルゴリズムを利用


※² 本研究では、RESITのこれまでの利用例や、今後の拡張可能性、計算負荷等を考慮しつつ、非線形の回帰モデルとして、Additive Noise Modelの一種である、以下の**一般化加法モデル (Generalized Additive Model)**を採用

$$x_i = \sum_{i \neq j} f_{ij}(x_j) + e_i$$


LiNGAMとRESITでの辺の検出力の差異

実際に非線形の数値シミュレーションに基づいて、LiNGAMとRESITの検出力を比べてみる



シミュレーションで正解とする因果モデル



シミュレーション
データ生成




誤差変数については一様分布を適宜仮定して、生成したデータ




事前知識なし因果探索

- ✓ 線形の部分については、LiNGAMは係数値も含め、正解モデルをおおむね再現
- ✓ 三角関数の成分 $x_3 \rightarrow x_2$ については、LiNGAMでは出力できていない
- ➡ 増加・減少の両方がwindowに表れる場合、線形回帰での検出には限界
- ✓ RESITでは非線形の部分も含めて、因果グラフが正しく再現されている


LiNGAMの結果 (係数は因果係数)



RESITの結果 (係数1.00は 依存性の有無)




RESITの結果のうち $x_3 \rightarrow x_2$ の依存性について 非線形回帰で再現した結果




コサイン型の依存性をおおむね再現

分析Aの結果①：線形性を仮定した因果探索と非線形に拡張した因果探索の比較（類型Ⅲの大学を例に）

【RESITでの探索結果】※ 辺に書かれている値は、影響が現れるという意味ですべて1。



LiNGAMでの探索結果




✓ 線形性の仮定のみで表現しきれなかった複雑な因果構造を、RESITが発見していると考えられる

分析Aの結果②：線形性を仮定した因果探索と非線形に拡張した因果探索の比較（類型Ⅲの大学を例に）


因果探索した結果から得られた非線形の総合因果効果の見積もり

※以下の例示は、辺のそのもの妥当性についてはいったん棚上げしておく


KAKEN→Papers_L1（ほぼ線形の関係）



AcaPos → Students_per_teacher_L1（非線形の関係）



Students_per_teacher→D_entrance_L1（非線形の関係）




- ✓ 本データセットで、今ある変数の範囲で定量的に因果分析するには、実際に探索した結果を見ても、**線形の関係のみで議論できる範囲を超えており、非線形性の議論が必要**となることが確かめられる

分析Bの結果①:介入を想定した非線形総合因果効果の可視化と統計的信頼性評価 (グラフの見方)

- ✓ pythonパッケージ "lingam"(<https://github.com/cdt15/lingam>)における
" $x_i \leftarrow x_j$ "の非線形効果の可視化・統計的信頼性評価の出力機能


例. DC1 → D_entrance (類型I)
(x_i :D_entrance, x_j :DC1)




分析Bの結果②:介入を想定した非線形総合因果効果の可視化と統計的信頼性評価 (DC1→D_entrance)

DC1 → D_entranceの非線形因果効果に関する大学類型間の比較

類型I



類型Ⅲ





※ スケールの差異は、横軸は類型 I とⅢの各データセットでの値域の違い、縦軸は類型 I とⅢのbootstrapでの予測値の範囲の違いによる。

- ✓ 類型 I では類型Ⅲよりも、D_entranceへのDC1の増による効果が表れにくいことが示唆される
(正の影響はありそうだが、この値域ではあまりD_entranceが類型Ⅲほど大きな値にもならず、頭打ちの傾向も示唆される)
→ これまでLiNGAMで示された結果 (高山ら、研究イノベ学会 (2024) など) とも概ね整合



分析Bの結果③:介入を想定した非線形総合因果効果の可視化と統計的信頼性評価（1年後のDC1採択者数への影響）

D_entrance → DC1_L1



- ✓ D_entranceでの1年後のDC1の効果は、類型 I では現れるとは考えにくい、類型 III ではD_entrance < 400 で現れているという計算（先輩が多いほど、DC1申請に当たってのノウハウが共有されやすい？）
→ これまでLiNGAMで示された結果（高山ら、研究イノベ学会（2024）など）とも概ね整合
- ✓ ただし、**類型 III でもD_entrance > 400では飽和の傾向**が示唆されている

KAKEN → DC1_L1



- ✓ 類型 III は、**KAKENの増による1年後のDC1への正の影響が表れる傾向**か（科研費に採択されたテーマが、DC1でもよい申請書につながる？）

本研究の成果

- 全86の国立大学11か年分の博士課程進学に関連する各変数で構築した、公開情報ベースでのデータセットを構築し、**非線形にも対応した因果探索アルゴリズムRESITで分析を実施**
- **DC1による博士課程進学者数への影響**について、線形性を仮定したアルゴリズムであるLiNGAM等よりも**高い感度で分析**できた。
- **類型Ⅲの研究大学**において、**博士課程進学者数の増加が翌年のDC1採択者数増につながる一方、その効果に飽和現象**があることも示唆された。
- **類型Ⅲの研究大学**において、**科研費の配分額がDC1採択者数増に影響を与える可能性**が観測・解釈された。

留意点・今後の展望

- ✓ 因果モデルを用いた**政策的なシミュレーション**（政策意志決定支援のためのマルチエージェントシミュレーション等）
- ✓ 高等教育論等の**政策研究の領域知識に基づいた、因果グラフの各辺の詳細な解釈・妥当性検証**
 - 👉 **大規模言語モデル（LLM）の活用可能性あり（次ページ参照）**


- ✓ 当グループでは別途、LLMを活用し、領域知識から見ても統計的に見ても、妥当な因果グラフを構築するための枠組みを、最近提案・実証したところ

1st step: Data-Driven Causal Discovery (without any constraints on the edges)

Input: Dataset

Pollution	Smoker	Cancer	X-ray	Dyspnoea
Low	True	True	True	True
High	False	True	False	True
...	...	...	...	...

Output: Causal Graph



SCD: statistical causal discovery

Not so plausible from both domain experts' point of view.

2nd step: Knowledge Generation on Causal Relationships by the LLM with ZSCoT

Input: prompts with the result of causal discovery

According to the result shown above, the state of "cancer" may have no direct impact on the state of "X-ray". Please explain whether this statistically suggested hypothesis is plausible with an explanation that leverages your expert knowledge on this causal relationship.



Output: response with the qualitative discussion on causal relationships in detail as domain experts



While it is suggested that there may not be a direct causal effect from the state of "Cancer" to the state of "X-ray", it seems to be not plausible considering the domain knowledge, as explained below: ...


4th step: Retrying Causal Discovery (with the constraints determined in 3rd step)

Input: Dataset + constraints

Pollution	Smoker	Cancer	X-ray	Dyspnoea
Low	True	True	True	True
...	...	...	...	...

Constraints:
Cancer → X-ray: forced, X-ray → Cancer: forbidden, etc.

Output: Modified Causal Graph



SCD: statistical causal discovery

Plausible both from domain experts' and statistical points of view!

Transforming the probability matrix generated in 3rd step into background knowledge for the causal discovery

3rd step: Knowledge Integration and Evaluation of the Probability of Causal Relationships with the LLM

Input: prompts with the dialog in 2nd step

Considering objectively this discussion above, if the state of "cancer" is changed, will it have a direct impact on the state of "X-ray"? Please answer this question with <yes> or <no>..



Output: <yes> or <no> with its log probability



Most likely response: Yes (log probability: -0.0408)
2nd most likely response: No (log probability: -3.219)
→ yes:96%, no: 4%

M. Takayama *et al.*, TMLR(2025) <https://openreview.net/forum?id=Reh1S8rxfh>

- ✓ これを活用した、RESITの結果解釈や、政策研究の領域知識から見た妥当性の担保も考えられる
- ✓ 一方、果たしてこのドメインでもLLMが領域知識に基づいて適切に動いてくれるか等は、別途評価が必要
→ 2B22の発表で詳しく議論します！